למידת מכונה – מטלה 2 (2026 סמסטר א')

מותאם למשרתי מילואים

לאחר שבמטלה 1 התמודדתם עם דילמות מעולם מדע הנתונים, באיסוף הנתונים, חישת הנתונים ויצירת ה-dataset, במטלה זו תשתמשו בסט הנתונים שהכנתם לצורך אימון ובחינה של מודלי למידת מכונה שונים, השוואה ביניהם ושיפורם.

<u>דגשים:</u>

- הקבצים הדרושים להגשה (המצוינים בסוף ההוראות) יוגשו לתיבת ההגשה במודל עד לתאריך ה-**5.2.2026 בשעה 9:59.** מספיקה הגשה של אחד מבני הזוג.
- **אורך הדו"ח לא יעלה על 10 עמודים** (לא כולל שער ותוכן עניינים), בגודל כתב 12, פונט Calibri ורווח של שורה וחצי. פלטים מרכזיים וגרפים יש לצרף **בגוף הדו"ח ולא בנספחים**.
- אנא שמרו על תמציתיות והתמקדו בתובנות המרכזיות. בחלק זה ישנן שאלות פתוחות, **ענו עליהן בקצרה (שורה - שתיים).**
- בכתיבת הדו"ח יש להשתמש **במונחים מקצועיים** בהקשרים הרלוונטיים.
- יש להגיש קובץ Word המאפשר השארת הערות על גביו - **אין להגיש קובץ PDF**.
- אין להשתמש בספריות NLP בשום שלב של המטלה.

<u>שאלות בנוגע למטלה, יש לפרסם בפורום הייעודי שייפתח במודל כדי שחברכם לקורס יוכלו ללמוד מהן.</u>

0. לפני שמתחילים (10 נק')

1. **חלקו את סט הנתונים לסט אימון וולידציה** בהתאם לשיטת הוולידציה שבחרתם במטלה 1. כדי לאפשר יכולת שחזור (reproducibility), קבעו random state כלשהו בעת החלוקה.

1. Model Training (45 נק')

1.1 Decision Trees (15 נק')

א. אימון וכוונון היפר-פרמטרים

- בנו עץ החלטה ובצעו תהליך של כוונון היפר-פרמטרים על מנת למצוא את הקונפיגורציה האופטימלית של המודל. ציינו אילו פרמטרים כיוונתם, מה משמעותם ואיזה טווח ערכים ניסיתם עבורם.
- מה **ביצועי המודל** המתקבלים על סט האימון וסט הוולידציה עבור המודל הטוב ביותר? מה ניתן להסיק מתוצאות אלה? באילו שיטות Evaluation בחרתם להשתמש?

ב. פירוש והבנת המודל

- אחד היתרונות של מודל עץ החלטה הוא יכולת **פירוש המודל** (interpretability או explainability), הסבירו את חשיבות תכונה זאת בהקשר חיזוי קטגוריית הכתבה וכיצד באה לידי ביטוי בעץ החלטה.
- הציגו גרף של השכבות העליונות של העץ שהתקבל.
- התבוננו בגרף שייצרתם ונסו להפיק ממנו תובנות לגבי דפוסים בנתונים ואופן קבלת ההחלטות של המודל.

1.2 Artificial Neural Networks (15 נק')

א. אמנו מודל MLP עם ערכי ברירת המחדל של ספרייה שתבחרו לצורך האימון.

- תארו את **מבנה המודל** והסבירו את משמעות המרכיבים השונים שלו (מספר נוירונים בשכבת הכניסה, מספר שכבות חבויות ומספר נוירונים חבויים בכל שכבה).
- מהם הביצועים המתקבלים על סט האימון וסט הוולידציה? מה ניתן להסיק מתוצאות אלה?

ב. בחרו מספר **היפר-פרמטרים** שברצונכם לכוון (כגון: מספר שכבות חבויות, מספר נוירונים בכל שכבה, learning rate, גודל batch, פונקציית אקטיבציה וכו').

- עבור כל היפר פרמטר שבחרתם: הסבירו מה תפקידו ברשת, מה המשמעות של הגדלה או הקטנה של ערכו, ואילו טווחי ערכים בחנתם ולמה.

- הציגו בטבלה את ערכי ההיפר-פרמטרים שנבחנו כפונקציה של אחוז הדיוק על סט האימון והוולידציה. מה ניתן להסיק מממצאים אלו?
- מהם אחוזי הדיוק המתקבלים על סט האימון וסט הוולידציה באמצעות המודל המדויק ביותר? אם קיים שיפור, האם ניתן לקשור אותו לבחירת ערכי ההיפר-פרמטרים? פרטו.

ג. הציגו גרף של הביצועים וה-Loss כפונקציה של **מספר ה-epoch**, עבור סט האימון והוולידציה. האם המודל מתכנס? ציינו באיזה מספר תבחרו ומדוע.

1.3 Clustering (15 נק')

א. במה שונה שיטת ניתוח אשכולות (Clustering) לעומת המודלים הקודמים שהרצתם? התייחסו להבדל בסט הנתונים ולמטרת משימת הלמידה.

- בחרו סט של פיצ'רים לצורך ביצוע Clustering, והריצו עליו את **אלגוריתם K-means עם ערכי K שונים**. ציינו באיזה סט פיצ'רים בחרתם, ובאיזו מטריקה למדידת מרחק בחרתם. הסבירו את בחירותכם.

ב. השוו את תוצאות ה-Clustering עבור ערכי K שונים שבחנתם.

- ציינו באילו מדדים השתמשתם כדי להשוות בין האשכולות ומדוע.
- מהו מספר האשכולות בו תבחרו?
- האם יש קשר בין האשכולות השונים למשתנה המטרה?

2. Evaluation (25 נק')

א. בחירת מודל:

- השוו בין ביצועי שלושת מודלי הסיווג (DT, MLP) בטבלה מסכמת.
- על איזה מהמודלים תמליצו? הסבירו מדוע (ניתן לערב שיקולים שאינם מדדי ביצוע).
- האם יש מגבלות למודלים שאימנתם? תארו מצב בו חסרון זה בא לידי ביטוי.
- באילו מדדי ביצוע השתמשתם בהשוואתכם?

ב. ניתוח ויזואלי של ביצועי המודל:

- צרו מטריצת מבוכה. האם קיימת הטיה כלפי אחת מהמחלקות? כיצד ניתן להסביר זאת בהתבסס על הנתונים?

ג. Overfitting:

- האם נתקלתם במצב של overfitting בעת יצירת אחד המודלים? כיצד זיהיתם זאת? (אם לא מצאתם – כיצד ניתן לזהות שמדובר בתופעה), תארו שיטה אחת להתמודדות.

ד. להגשה: model_training.ipynb (מחברת ה-Python לשלבים 0-2).

Test (20 נק')

שלב זה מדמה **חיזוי על נתוני העולם האמיתי**, כלומר נתונים שאין ברשותכם בעת פיתוח המודל.

על חלק זה תקבלו ציון בהתאם לביצועי הקלסיפיקציה של המודל שלכם.

המודל שלכם יבחן על יכולת הסיווג שלו עבור כתבות שיתפרסמו לאחר מועד ההגשה של המטלה באתר The Guardian.

בצעו את השלבים הבאים:

1. צרו תיקיית פרויקט בשם #Group (במקום # בא מספר הקבוצה).
2. צרו תיקייה ריקה בשם "Test" תחת תיקיית #Group. בעת הבדיקה, קבצי txt חדשים יוכנסו לתיקיית Test.
3. צרו קובץ classification.py הלוקח את הקבצים תחת תיקיית Test, מעביר אותם תהליך זהה לסט האימון (כמו שביצעתם במטלה 1) ומבצע סיווג לקטגורית הכתבה לפי המודל הסופי שלכם.

   על הפלט להיות בפורמט csv בצורה הבאה:

URL	Category
https://www.theguardian.com/...	'news'
...	...

דגשים:

1. יש לקבוע בתחילת המטלה seed למען שחזור תוצאות מהימן (כמו שלמדנו בתרגול 1).
2. הימנעו ממצב של Data Leakage – מצב שבו מידע מה-Test Set נכנס בשוגג לשלב האימון, וגורם למודל ללמוד נתונים שלא אמור היה לראות — מה שמוביל לביצועים מטעים.
3. רצוי להשתמש ב-Plots מספריות seaborn, matplotlib על מנת להציג את השלבים השונים בקוד.
4. אנא בדקו ששלב ה-Test (4) מתפקד כראוי לדרישות.
5. להגשה:
   - תיקיית zip בשם #Group (# מציין את מספר הקבוצה) המכילה:
     - model_training.ipynb (מחברת ה-Python לשלבים 0-2).
     - test (תיקייה ריקה).
     - classification.py (מבצע classification על קבצים תחת תיקיית Test).
   - דו"ח מטלה 2 בשם: Part_B_Group_#

- אין להגיש את קובץ המודל הסופי שלכם, משום שקבצים אלו נוטים עלולים להיות כבדים מדי לתיבת ההגשה. במקום זאת – הגישו קוד היוצר את מופע המודל ומאמן אותו כנדרש.

בהצלחה!

נספח - מקורות נוספים:

- ככל שארגז הכלים של מדען הנתונים רחב ומגוון יותר, כך עולה היכולת שלו להתמודד עם בעיות מורכבות ומגוונות בתחומים שונים. אנו מעודדים אתכם להרחיב את הידע שלכם גם מעבר לחומר שנלמד בקורס, ולהיחשף למקורות נוספים שיכולים להעשיר את העבודה שלכם ולשפר את איכות הפתרונות.
- להלן מספר מקורות מומלצים ללמידה עצמאית, העמקה וחיפוש פתרונות:
- **Documentation**:
  - תיעוד (דוקומנטציה) של ספריות שאתם משתמשים בהן, כגון: scikit-learn, keras, tensorflow ועוד. פעמים רבות תמצאו שם פונקציות, פרמטרים וטכניקות שיכולות לחסוך לכם זמן ולשפר את המודל.
- **קהילות אונליין ושאלות-תשובות:**
  - קבוצת פייסבוק: מומלץ לחפש פתרונות קיימים או לפרסם שאלות ולקבל עזרה מקהילת המומחים. דוגמה: Machine & Deep learning Israel
  - Stack Overflow - שאלות על תקלות בקוד, פתרונות נפוצים וביצועים.
  - Reddit - דיונים, המלצות על כלים ומאמרים. DataScience MachineLearning
  - Kaggle Discussions - קהילת Data Science פעילה עם דוגמאות, קוד פתוח וניתוחים. קישור
- **מאמרים אקדמיים וחומר מתקדם**
  - Google Scholar – חיפוש מאמרים אקדמיים לפי נושא, אלגוריתם או גישה מסוימת.